Programmation parallèle

Cours 3 : Programmation avec MPI

Ahmad AUDI
ahmad.audi@ign.fr

MPI
Une bibliothèque de communication par échange de messages

Qu'est ce que MPI?

- *Message Passing Interface :* standard d'interface de bibliothèque de communication et d'environnement parallèle, permettant de faire communiquer par échange de messages des processus *:*
  - Distants
  - Sur des machines qui peuvent être hétérogènes

- Pour des applications écrites en C, en C++ ou en Fortran

- Historique :
  - PVM : *Parallel Virtual Machine*
  - MPI-1 : 1994
  - MPI-1.2 : clarification du standard MPI-1
  - MPI-2 : 1997 (et MPI-2.1 adopté en 2008)
  - MPI-3 : en cours de finalisation

- Exemples d'implémentations :
  - Domaine public : LAM, MPICH, OpenMPI,
  - Implémentation constructeurs : IBM, SUN…

Qu’est ce qu’il y a dans MPI?

- Des communications point-à-point
  - Plusieurs modes de communication
  - Support pour les buffers structurés et les types dérivés
  - Support pour l’hétérogénéité
- Routines de communications collectives
  - Communications dans un « groupe » ou un « sous groupe » de processus
  - Opérations prédéfinies ou définies par l’utilisateur

Comment programmer sous MPI?

- Chaque processus a son propre flot de contrôle et son propre espace d'adressage(→MIMD)
  - mais toutes les affichages sont renvoyés sur la machine locale
- Modèles de programmation possibles : SPMD ou MPMD
- Utilisation d'une représentation interne des données
  - masque l'hétérogénéité
- Gestion de la communication par l'intermédiaire des routines de la librairie
  - les nom des routines MPI débutent par « MPI_ »;

Primitives de Bases

- Pour **l'initialisation**, on utilise la primitive MPI_Init qui doit être la première fonction MPI appelée :

```
int MPI_Init(int* argc, char*** argv);
```

- Pour **sortir de MPI**, on utilise MPI_Finalize qui doit être la dernière fonction MPI appelée. Cette primitive doit être impérativement appelée par tous les processus :

```
int MPI_Finalize();
```

Notion de communicateur

- Type MPI_Comm

- Un ensemble statique de processus qui se connaissent.
  - Peut être crée ou détruit en cours d'application
  - Tous les processus d'un communicateur ont un *rang* différent, compris entre *0* et *P-1* (où *P* est le nombre de processus dans le communicateur)

- Chaque communication MPI a lieu par rapport à un communicateur
  - Définit les processus concernés par la communication
  - Utile pour les communications collectives

- Un processus peut appartenir à plusieurs communicateurs
  - Peut avoir un rang différent dans chaque communicateur

- MPI_COMM_WORLD est un communicateur prédéfini qui contient tous les processus

Primitives de Bases

- Combien de processus y a-t-il dans le communicateur ?

```
int MPI_Comm_size(MPI_Comm comm, int *size);
```

- Qui suis-je ?

```
int MPI_Comm_rank(MPI_Comm comm, int *rank);
```

MPI_COMM_WORLD

- Le communicateur MPI_COMM_WORLD contient tous les processus démarrés (statique en MPI-1)
- Chaque processus possède un rang unique dans MPI_COMM_WORLD

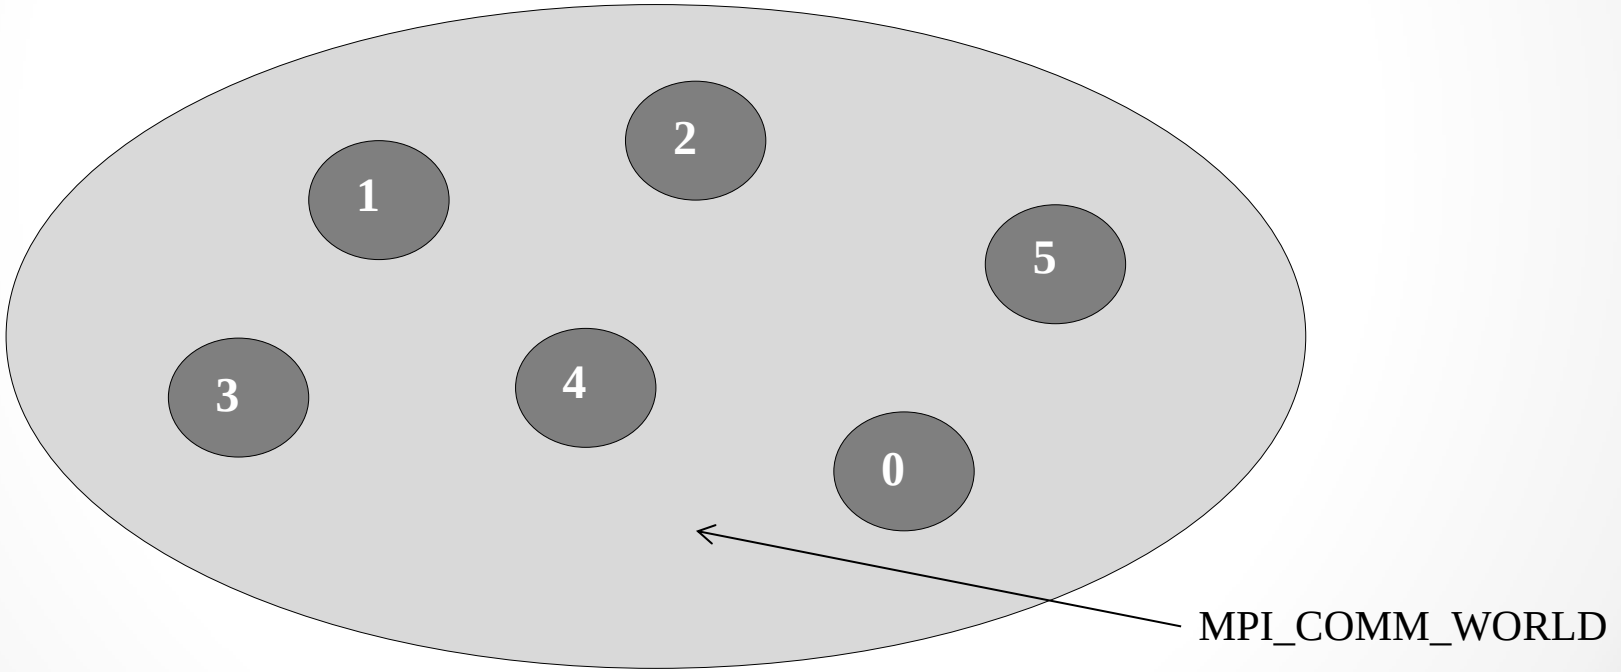

Structure d'un message sous MPI

- Un message est divisé en une zone de données et une enveloppe
  - Les données :
    - Adresse du buffer
    - Nombre d'éléments
    - Type
  - L'enveloppe :
    - Rang (identité) du processus
      - Pour les envois : indique le destinataire
      - Pour les réceptions : indique l'expéditeur
    - Étiquette du message(tag) qui permet au programme de distinguer différentes messages
    - Communicateur

Comment typer les messages ?

- L'étiquette du message : `int tag`
- Permet de séparer données et contrôle
- Valeur d'un tag 0 .. UB(*Upper Bound*)
  - MPI garantit que UB ≥ 32 767
  - LAM sur LINUX : UB = 134 973 172
- Un processus peut se mettre en attente d'un message de tag donnée
  - Le tag du message attendu doit être égal au tag d'un message reçu (qui n'est pas forcément le premier message reçu)

- Un processus peut se mettre en attente d'un message de tag quelconque : MPI_ANY_TAG

Contenu des messages MPI

- Vous pouvez avoir
  - Des types élémentaires
  - Des tableaux de types élémentaires
  - Des zones contiguës de données
  - Des blocs de types avec saut
  - Des structures
  - …
- Construction (éventuellement récursive) de ces types dérivés, puis enregistrement avec `MPI_Type_commit`(et destruction avec `MPI_Type_free`), par tous les processus
- Création des types dérivés à l'exécution → peuvent dépendre des paramètres de l'application.

Passage de messages : qu'est ce que c'est ?

- Plusieurs processus exécutent le même programme mais pas forcement les mêmes parties.
- Chaque processus dispose de ses propres données et n'a pas d'accès direct aux données des autres processus
- Les données du programme sont stockés dans la mémoire du processeur sur lequel s'exécute le processus
- Une donnée est échangée entre deux ou plusieurs processus via un appel à des routines particulières et spécialisées

Types de données élémentaires

MPI	C
MPI_CHAR	signed char
MPI_CHAR	signed short
MPI_SHORT	signed int
MPI_UNSIGNED_CHAR	unsigned char
MPI_UNSIGNED_SHORT	unsigned short
MPI_UNSIGNED_INT	unsigned int
MPI_UNSIGNED_LONG	unsigned long
MPI_FLOAT	float
MPI_DOUBLE	double
MPI_LONG_DOUBLE	Long double

Les communications MPI

- Communications **fiables**
  - Tout message émis est reçu exactement une fois (ni perte, ni duplication)

- Communications **FIFO** (First In – First Out)
  - Pour tout couple de processus (Pi, Pj) :
    - Pour tout couple (m, m') de messages émis par Pi à destinataire de Pj : → si m est envoyé avant m', alors m est reçu avant m'
  - Cette condition ne s'applique pas si les destinataires (ou les émetteurs) sont différents → système **non déterministe**, plusieurs exécutions possibles :

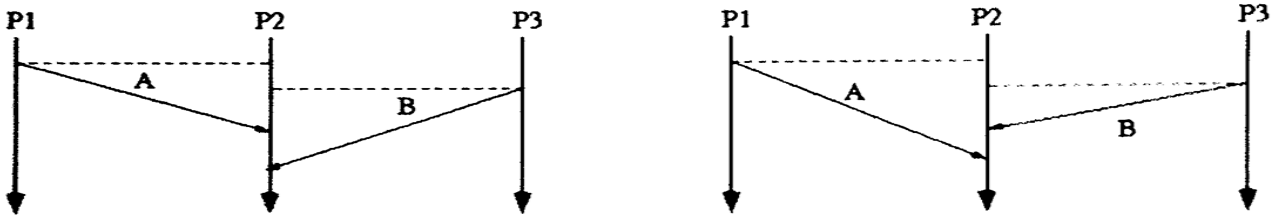

Les communications point-à-point

- Forme la plus simple de communication

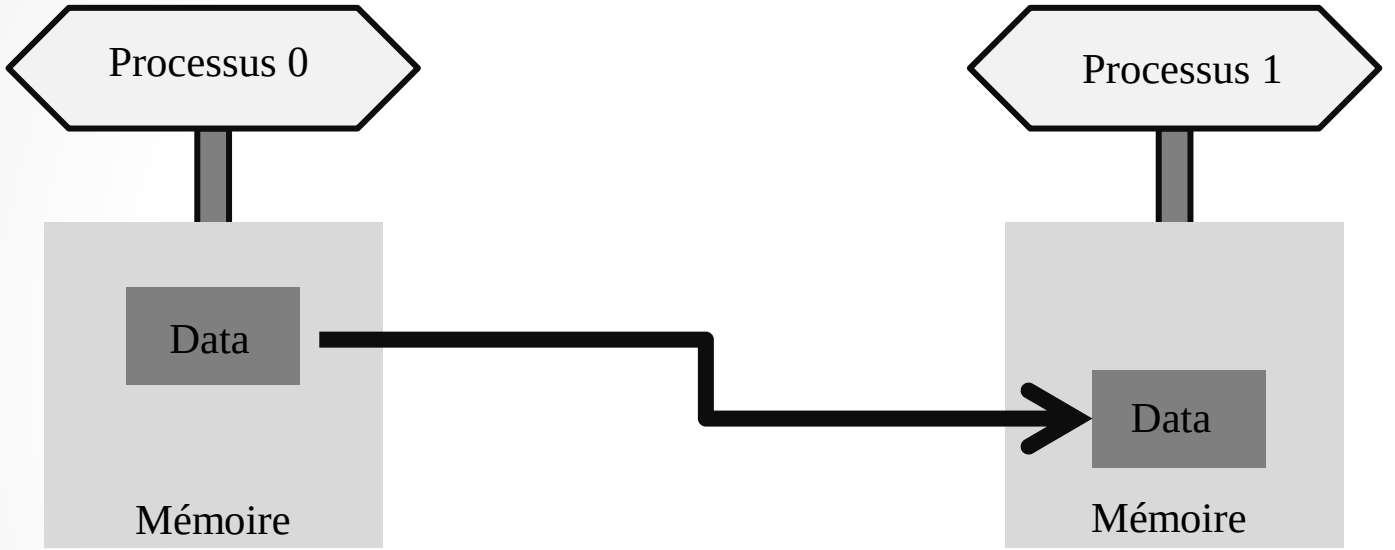


```
send(buffer, size, [tag], destination)
receive(buffer, buffer_size, [tag], [source])
```

Sous-ensemble MPI-1

- Il suffit de 6 routines pour écrire des programmes MPI simples :

```
MPI_Init(…)
MPI_Comm_size(…)
MPI_Comm_rank(…)
MPI_send(…)
MPI_receive(…)
MPI_Finalize(…)
```

MPI est simple!

Exemple

```
#include <mpi.h>
int main(int argc, char *argv[]){
  char msg[20];
  int my_rank;
  MPI_Status status;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);

  if (my_rank == 0) { /* Hi! I'm process 0! */
    strcpy(msg, "Hello C world !");
    MPI_Send(msg, strlen(msg)+1, MPI_CHAR, 1 /* destinataire */,
             99 /* tag */, MPI_COMM_WORLD);
  }
  else {
    MPI_Recv(msg, 20, MPI_CHAR, 0 /* emetteur */,
             99 /* tag*/, MPI_COMM_WORLD, &status);
    printf("I received %s!\n", msg);
  }
  MPI_Finalize();
}
```

MPI : modes de communication

- Opération à réaliser :
  - Envoi par P0 du contenu du buffer A
  - Réception par P1 des donnés et stockage dans un buffer B

- Options :
  - Communication synchrone / asynchrone
  - Communication bloquante / non bloquante

MPI : Communications bloquantes

- Le processus qui effectue une action de communication ne rend la main qu'une fois l'action terminée

- **Emission bloquant `MPI_SEND()` :**
  - Le processus émetteur rend la main dès que les données à expédier sont sauvegardés (expédiées ou bufférisées) → on peut modifier sans délais les zones de données émises

- **Réception bloquant `MPI_RECV()` :**
  - Le processeur récepteur ne rend la main que lorsqu'il a bien reçu les données → il fournit les synchronisations désirées

- Emission :
  - Lorsque l'émission se termine, le buffer qui contenait les données envoyées peut être réutilisé
  - Dans le cas général, rien n'indique que les données aient été effectivement reçues par le destinataire

- Réception
  - Lorsque la réception se termine, les données sont disponibles dans le buffer du destinataire

Réception bloquante `MPI_Recv`

- `MPI_Recv` retourne (se termine) quand le transfert est terminé
- Lorsque la réception se termine, les données sont disponibles dans le buffer du destinataire

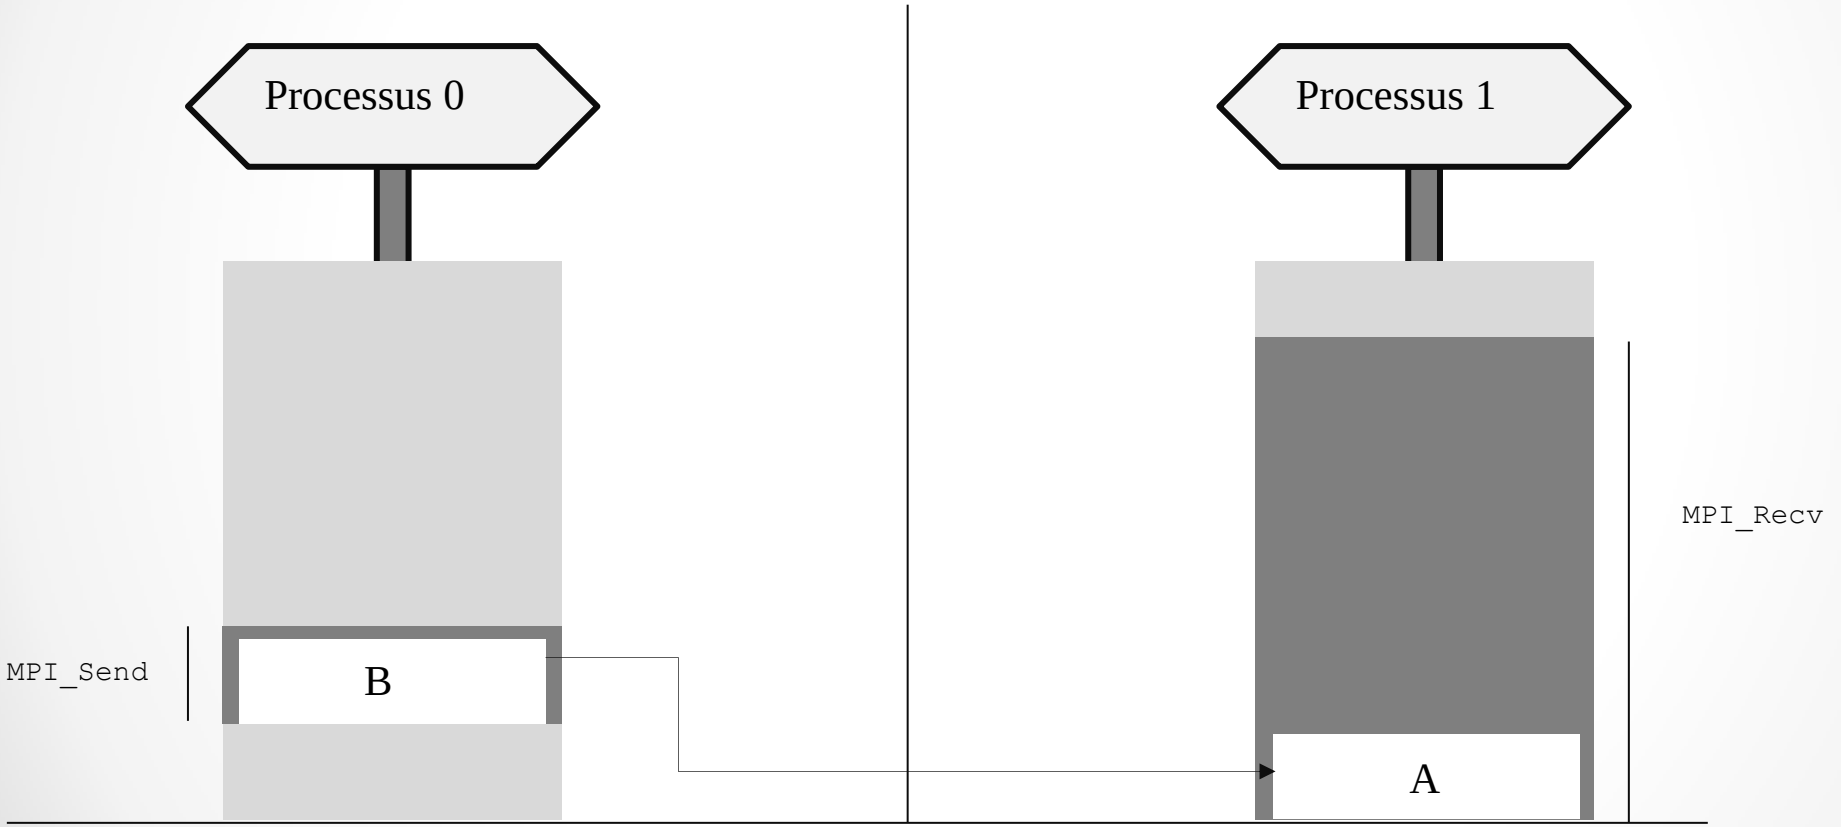

MPI : Communications non bloquantes

- La primitive se termine (retourne) « immédiatement »
  - Lorsqu'une émission non bloquante se termine, les données pas forcément été extraites du buffer d'émission
  - Lorsqu'une réception non bloquante se termine, le buffer de réception n'a pas forcément été rempli

- Nécessité de vérifier que la communication s'est terminée avant de réutiliser le buffer
  - Primitive de test et d'attente : MPI_Test(), MPI_Wait()

- Primitive terminée ≠ communication terminée !

Réception non bloquante `MPI_Irecv`

- `MPI_Irecv()` peut retourner avant même le début du transfert
- `MPI_Wait()` retourne quand le transfert est terminé
- Lorsqu'une réception non bloquante se termine, le buffer de réception n'a pas forcément été rempli

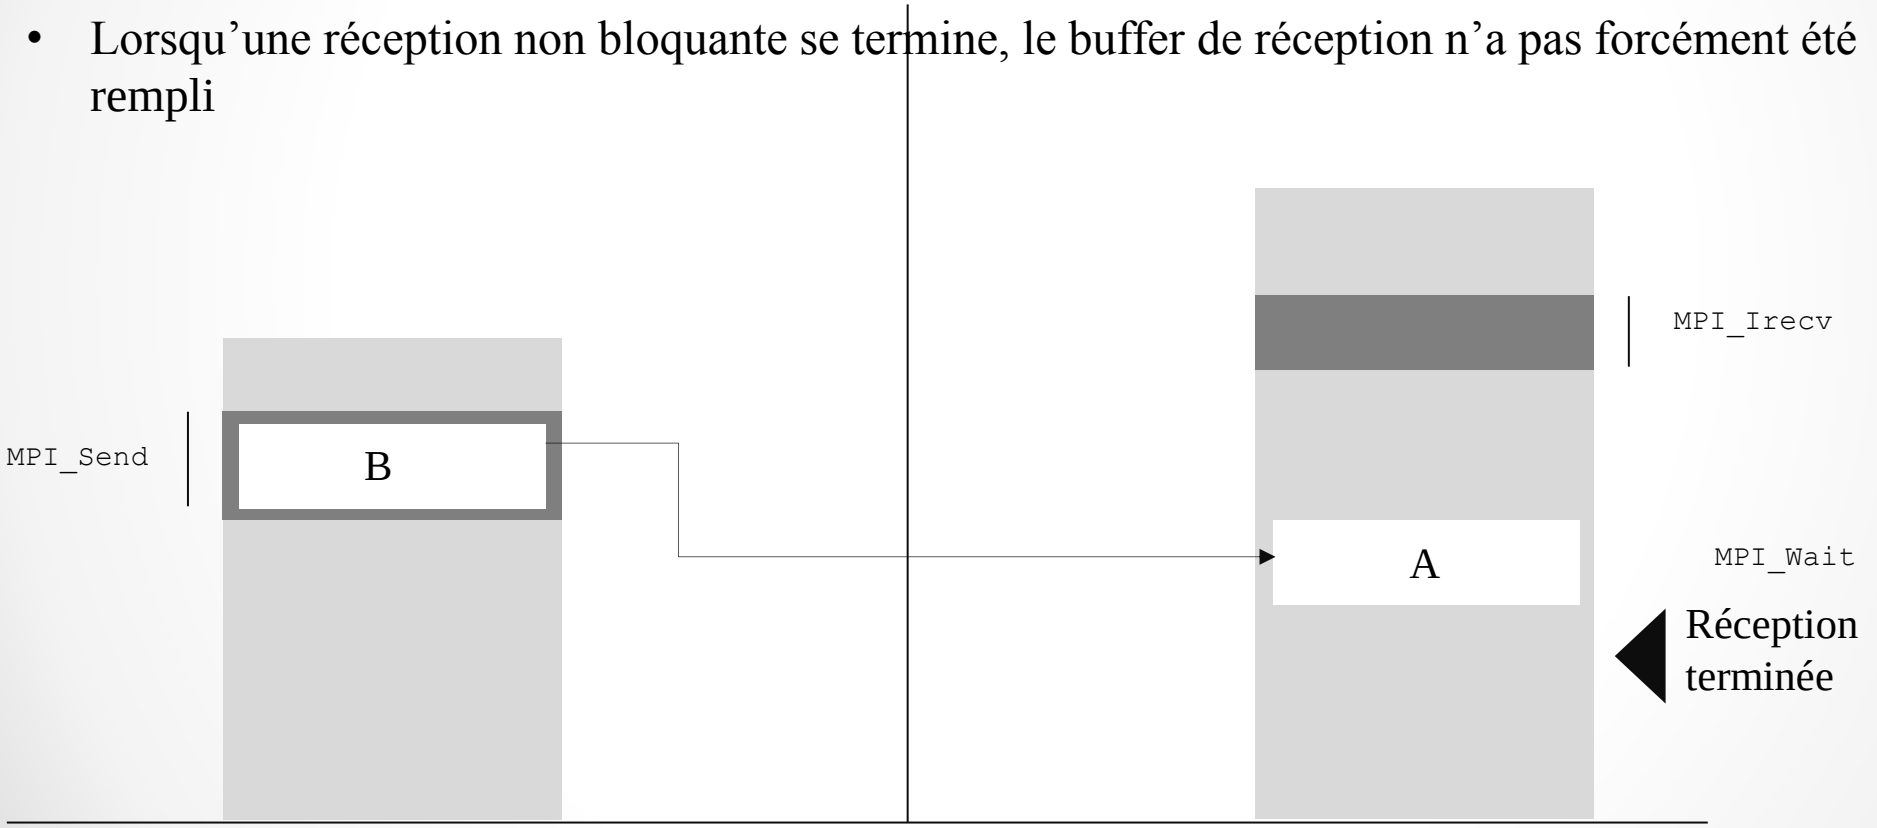

Emission synchrone ou standard

- Emission **synchrone** : terminée quand les données sont entièrement reçues par le destinataire

- Emission **standard** : terminée quand les données sont complètement :
  - Soit reçues par le destinataire (mode synchrone ou « rendez-vous »)
  - Soit transférées dans un tampon système intermédiaire (mode « envoi immédiat »)

- Emission standard – **attention** :
  - L'utilisation du tampon intermédiaire dépend de l'implémentation MPI, et des conditions courantes d'exécution de l'application
  - Man MPI_Send LAM : this function may block until the message is received. Whether or not MPI_Send blocks depends on factors such as how large the message is, how many messages are pending to the specific destination, etc.
  - En général : message courts → envoi immédiat
    message longs → mode rendez-vous

Emission bloquante synchrone `MPI_Ssend`

- `MPI_Ssend()` retourne quand les données sont entièrement reçues par le destinataire

- Niveau MPI : pas besoin de tampon intermédiaire, attendre que le réception soit prêt pour transférer

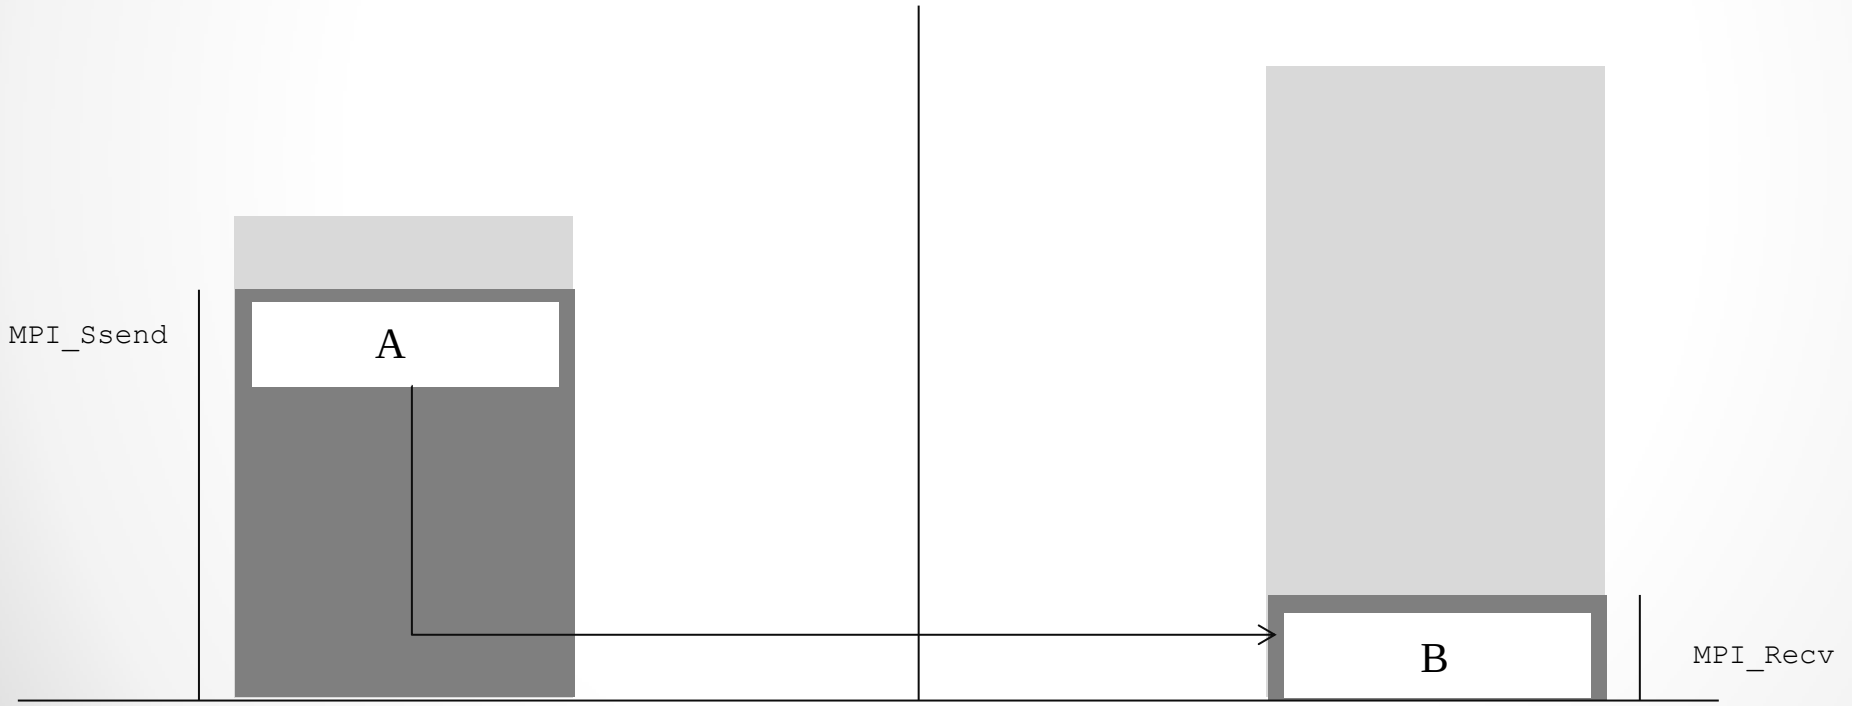

Emission bloquante standard MPI_Send

- `MPI_Send()` retourne quand les données sont reçues ou copiées dans un tampon intermédiaire
- Niveau MPI : utiliser un tampon intermédiaire, s'il peut contenir les données

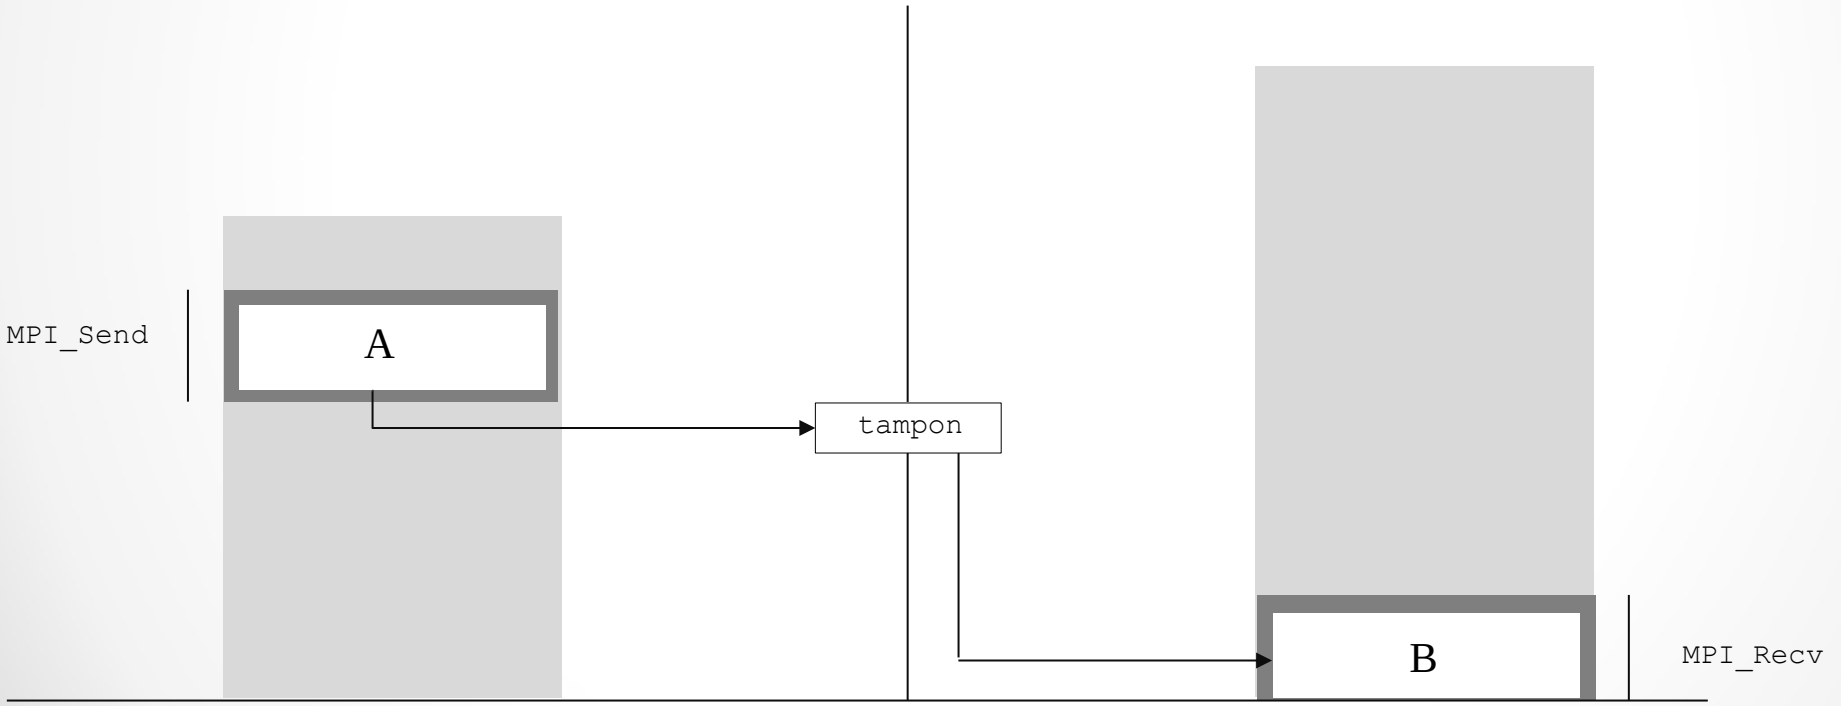

Emission non bloquante synchrone MPI_Issend

- `MPI_Issend()` peut retourner avant même le début du transfert
- `MPI_Issend()` retourne quand les données sont complètement reçues par le destinataire

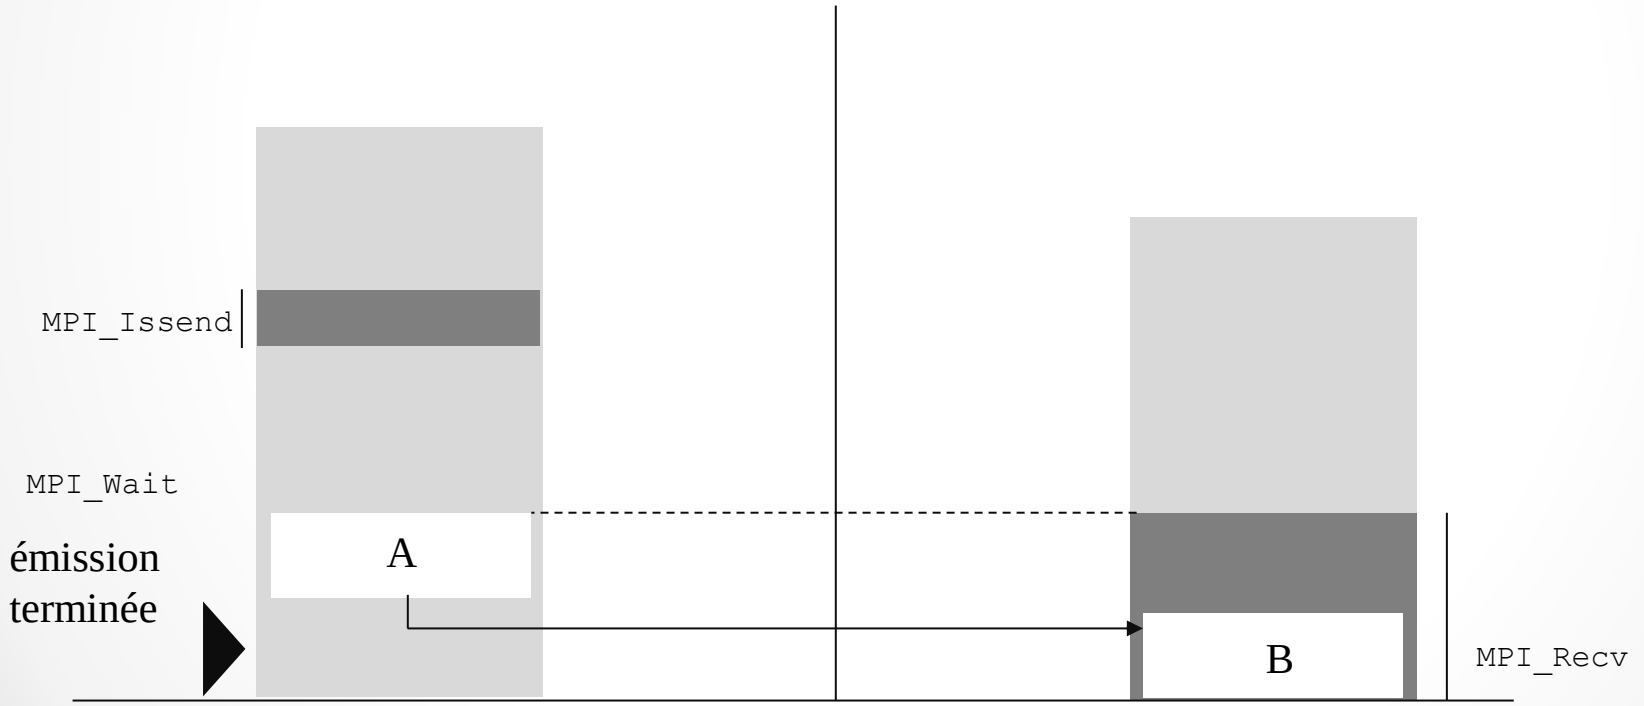

Emission non bloquante standard MPI_Isend

- `MPI_Isend()` peut retourner avant même le début du transfert ou la recopie dans le tampon, intermédiaire
- `MPI_wait()` retourne quand les données sont complètement reçues par le destinataire ou recopiées dans le tampon intermédiaire

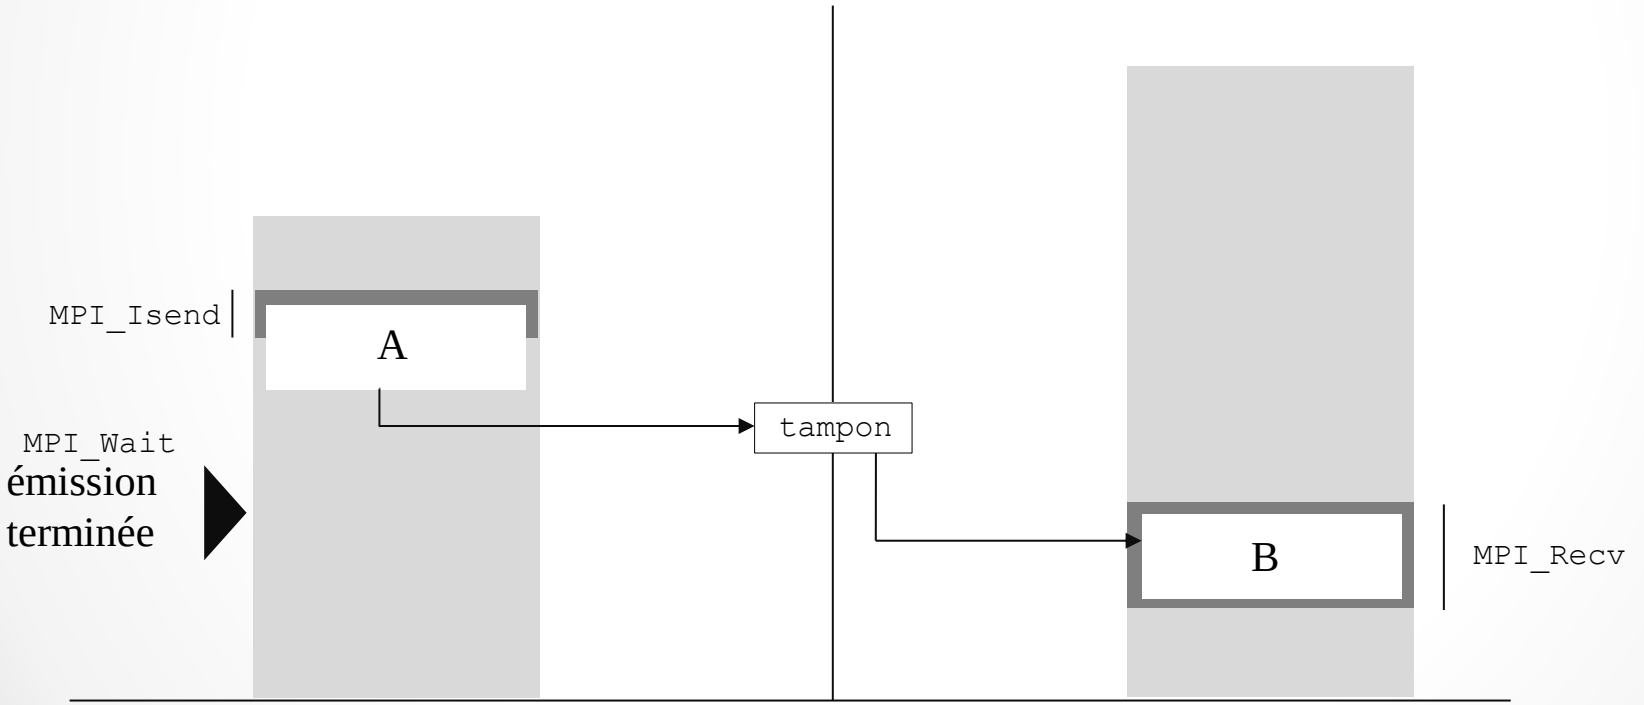

Exemple avec tampon intermédiaire

Les primitives MPI

- Emission :
  - `MPI_Ssend` : synchrone bloquant
  - `MPI_Send` : standard bloquant
  - `MPI_Issend` : synchrone non-bloquant
  - `MPI_Isend` : standard non-bloquant

- Réception :
  - `MPI_Recv` : standard bloquant
  - `MPI_Irecv` : standard non-bloquant

- **Les primitives non-bloquantes mobilisent beaucoup de ressources en mémoire**
  - **À n'utiliser que s'il y a de bonnes possibilités de recouvrement des communications par le calcul (pour des raisons d'optimisation)**

Emission : les paramètres

- Emission bloquante : **`Send`** et **`Ssend`**
  - L'adresse de début de la zone d'émission : `void* buf`
  - Le nombre de données envoyées : `int nb`
  - Le type des données (homogènes) : `MPI_Datatype dtype`
  - L'identité du destinataire : `int dest`
  - L'étiquette du message : `int tag`
  - Le communicateur : `MPI_Comm comm`

- Emission non bloquante : **`Isend`** et **`Issend`**
  - En plus des paramètres ci-dessus, un identificateur de requête (paramètre de sortie) :
    `MPI_Request *req`
    → pour identifier par la suite l'émission dont on testera la terminaison

Réception : les paramètres

- Emission bloquante : **`Recv`**
- L'adresse de début de la zone d'émission : `void* buf`
  - Le nombre de données envoyées : `int nb`
  - Le type des données (homogènes) : `MPI_Datatype dtype`
  - L'identité de l'émetteur: `int source`
  - L'étiquette du message : `int tag`
  - Le communicateur : `MPI_Comm comm`
  - Les informations complémentaires : `MPI_Status *status`

- Emission non bloquante : **`IRecv`**
  - En plus des paramètres ci-dessus, un identificateur de requête (paramètre de sortie) : `MPI_Request *req`
    → pour identifier par la suite la réception dont on testera la terminaison
  - Pas de 'status' en non bloquant : affecté seulement lorsque la réception est effective (voir `MPI_Wait`)

Les « jokers »

- Pour recevoir un message dont on ne connait pas l'émetteur a priori
  - `MPI_ANY_SOURCE`
- Pour recevoir un message dont on ne connait pas l'étiquette a priori
  - `MPI_ANY_TAG`
- Dans ce cas, possibilité de récupérer l'identité de l'émetteur ou l'étiquette du message à travers « status »

L'objet status

- Pour obtenir des informations sur le message après réception

- Structure de type prédéfini `MPI_Status`
  - Accès à la valeur de l'étiquette(tag) : `MPI_TAG`
  - Accès à l'identité de l'émetteur : `status.MPI_SOURCE`

- Peut être interrogé par l'intermédiaire d'une routine
  - `MPI_Get_count(&status, datatype, &count);`
    - Renvoi dans `count` le nombre d'objets de type datatype reçus

Exemple 2 (avec 3 processus)

```
int main(int argc, char *argv[]){
   int msg = 2;
   int my_rank;
   MPI_Status status;

   MPI_Init(&argc, &argv);
   MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);

   if (my_rank == 0) { /* Hi! I'm process 0! */
      MPI_Recv(&msg, 1, MPI_INT, MPI_ANY_SOURCE, 99,
                                              MPI_COMM_WORLD, &status);
      printf("Hello %d !\n", status.MPI_SOURCE);
      MPI_Recv(&msg, 1, MPI_INT, MPI_ANY_SOURCE, 99,
                                              MPI_COMM_WORLD, &status);
      printf("Hello %d !\n", status.MPI_SOURCE);

   } else {
      MPI_Send(&msg, 1, MPI_INT, 0, 99, MPI_COMM_WORLD);
   }
   MPI_Finalize();
}
```

Attention aux blocages…

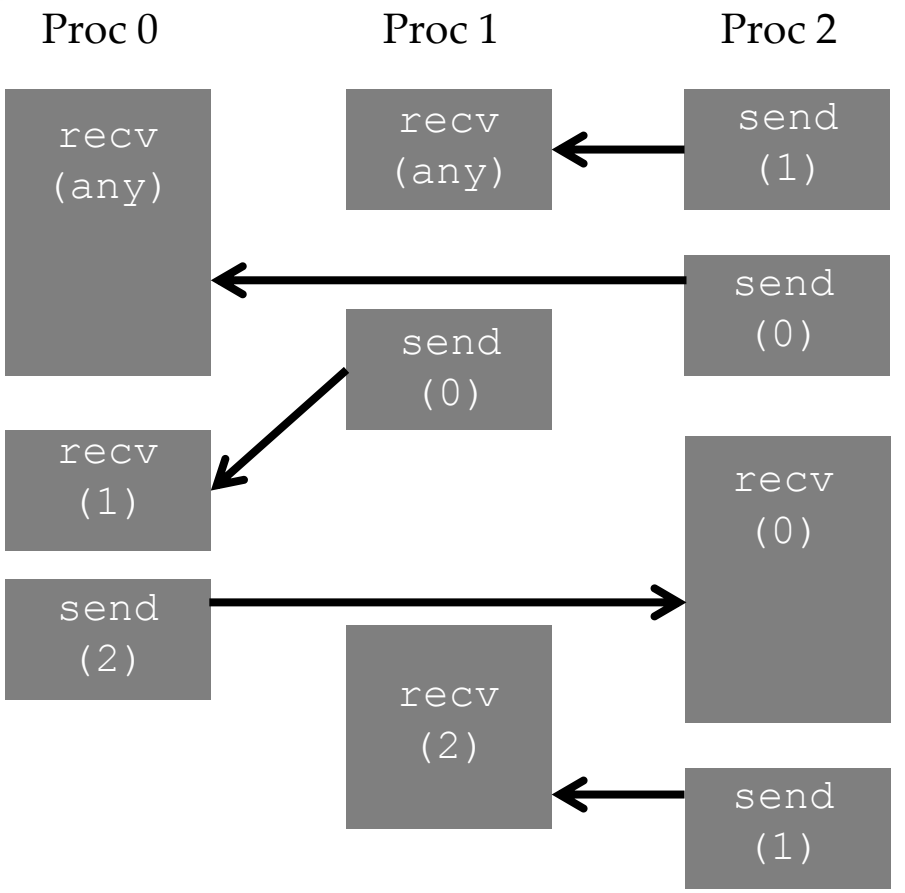

Exécution OK!

Fin de communication non-bloquante

- Tester l'arrivée du message
  - Le message que j'ai envoyé a-t-il été transmis ?
  - Le message que j'attends est-il arrivé?

```
MPI_test(MPI_Request *req, int *flag, MPI_Status *status);
```

- `'req'` identifie la communication
- `'flag'` donne la réponse :
  - `*flag = 1`: la communication est terminée
  - `*flag = 0`: la communication est en cours

- Attendre l'arrivée du message :
  - `MPI_wait(MPI_Request *req, MPI_Status *status);`

Exemple 3 (avec 3 processus)

```
#include <mpi.h>
int main(int argc, char **argv) {
  char msg[20];int my_rank;
  MPI_Status status; MPI_Request request;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);
  if (my_rank == 0) { /*-- process 0 --*/
    sleep(5);
    strcpy(msg, "Hello world !");
    MPI_Send(msg, strlen(msg)+1, MPI_CHAR, 1, 7, MPI_COMM_WORLD);
  } else {
    MPI_Irecv(msg, 20, MPI_CHAR, 0, 7, MPI_COMM_WORLD, &request);
    sleep(1);  /* je fais autre chose, du calcul par exemple */
    MPI_Wait(&request, &status);
    printf("Je recois : %s\n", msg);
    }
  MPI_Finalize();
}
```

Test du contenu d'un message

- Utile si le contenu du message dépend
  - De l' émetteur
  - Ou de l'étiquette
  - Ou des deux

```
MPI_Probe(int source, int tag, MPI_Comm com, MPI_Status *status);
```

- On utilise le status pour identifier le message (si jokers) et/ou définir une zone de réception de la taille exactement nécessaire:

  `MPI_Probe → status → MPI_Get_count → malloc → MPI_Recv`

- Existe aussi en non-bloquant :

```
MPI_Iprobe(int source, int tag, MPI_Comm com, int *flag, MPI_Status *status)
```

Communications collectives

Principes :

- Routines de haut niveau permettant de gérer simultanément plusieurs communications
- Doivent être appelées par tous les processus du communicateur

Exemples :

- Barrière de synchronisation : tout le monde attend à un point de RDV
  - `Int MPI_Barrier(MPI_Comm comm)`

  → bloque les processus de comm jusqu'à ce qu'ils aient tous exécuté la primitive

- Broadcast : envoi d'un message à tout le monde
- Réception / collection de données
- Réduction (`MPI_Reduce`) : combinaison des données de plusieurs processus pour obtenir un résultat (somme, max, min)
- Autres : `MPI_ALLtoall`…

La diffusion d'une donnée

```
Int MPI_Bcast(void* buf,
              int count,
              MPI_Datatype dtype,
              int root,
              MPI_Comm comm)
```

- `root` émet le contenu de sa variable `buf`
- Tous les processus de `comm` reçoivent le contenu de `buf`

Exemple de broadcast

```
#include <mpi.h>

main(int argc, char **argv) {
   char msg[20];
   int my_rank;
   MPI_Status status;

   MPI_Init(&argc, &argv);
   MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);
   if (my_rank == 0) { /*-- process 0 --*/
      strcpy(msg, "Hello world !");
   }

   MPI_Bcast(msg, 20, MPI_CHAR, 0, MPI_COMM_WORLD);
   printf("Je suis %d et je recois : %s\n", my_rank, msg);
   MPI_Finalize();
}
```

Répartition de données

```
Int MPI_Scatter(void* sbuf,
                int scount,
                MPI_Datatype sdtype,
                void* rbuf,
                int rcount,
                MPI_Datatype rdtype,
                int root,
                MPI_Comm comm)
```

- `root` envoie au processus *i* `scount` données à partir de l'adresse :
  `sbuf +i*scount*sizeof(sdtype)`

- Les données sont stockés par chaque récepteur à l'adresse :
  `rbuf`

Exemple de Scatter à 5 processus

```
#include <mpi.h>
main(int argc, char **argv) {
  char msg[10];
  char recu;
  int my_rank;
  MPI_Status status;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);
  if (my_rank == 2) { /*-- process 2 --*/
     strcpy(msg, "abcde");
  }

  MPI_Scatter(msg, 1, MPI_CHAR, &recu, 1, MPI_CHAR,
                    2, MPI_COMM_WORLD);
  printf("Je suis %d et je recois : %c\n", my_rank, recu);
  MPI_Finalize();
}
```

Collections de données

```
Int MPI_Gather( void* sbuf,
                int scount,
                MPI_Datatype sdtype,
                void* rbuf,
                int rcount,
                MPI_Datatype rdtype,
                int root,
                MPI_Comm comm)
```

- `root` stocke les données reçues par i à l'adresse :
  `rbuf +i * rcount * sizeof(rdtype)`

- Chaque processus(y compris `root`) envoie à root `scount` données à partir de l'adresse `rbuf`

Exemple de Gather à 5 processus

```
main(int argc, char **argv) {
  char msg[10];
  char envoi = 97;     /* = 61h : code ascii de a */
  int my_rank;
  MPI_Status status;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &my_rank);
  envoi += (char) my_rank;
  MPI_Gather(&envoi, 1, MPI_CHAR, msg, 1, MPI_CHAR,
             3, MPI_COMM_WORLD);
  if (my_rank == 3) {    /* je suis root */
     msg[5] = '\0';      /* fin de chaine */
     printf("contenu de msg : %s\n", msg);
  }
  MPI_Finalize();
}
```

contenu de msg : abcde

Compilation et Exécution

- La compilation se fait avec la commande :
  `mpicc` *`prog.c`* `-o` *`executable`*

- Chaque programme se compile séparément.

- L'exécution d'une application MPI se fait avec la commande :
  `mpirun -np` *`nb_processus executable`*